



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

INTELIGENCIA ARTIFICIAL

EJERCICIOS DE EMBEDDINGS

JUAN FERNANDO PEREZ OLAYA
NELSON DAVID GUTIERREZ MEDINA
OSCAR FABIAN LEON TRIANA
SNEIDER MONROY QUIROGA
WILKYN JULIAN VARGAS BAHAMON

CORHUILA

DOCENTE: JOSE MIGUEL LLANOS MOSQUERA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

CORPORACION UNIVERSITARIA DEL HUILA CORHUILA
ING. EN SISTEMAS
NEIVA - HUILA
2026





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

Tabla de Contenido

Tabla de Contenido	2
Lista de Figuras	3
1 Introducción	4
2 Objetivos Generales	5
3 Objetivos Específicos	6
4 Marco Teórico	7
5 Desarrollo	8
5.1 Instalación de Dependencias	8
5.2 Conceptos Fundamentales	9
5.3 Word2Vec - Entrenamiento Práctico	11
5.4 Visualización con t-SNE	13
5.5 Clasificación de Textos con Embeddings	15
Conclusiones	17
Bibliografía	18

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

Lista de Figuras

Figura 1 Código del Ejercicio 1	8
Figura 2 Código del Ejercicio 2	9
Figura 3 Resultado del Ejercicio 2	10
Figura 4 Código del Ejercicio 3	11
Figura 5 Resultado del Ejercicio 3	12
Figura 6 Código del Ejercicio 4	13
Figura 7 Resultado del Ejercicio 4	14
Figura 8 Código del Ejercicio 5	15
Figura 9 Continuación del Código mas Resultado del Ejercicio 5	16

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

1 Introducción

En el presente taller se aborda el estudio de las representaciones de texto en el campo de la Inteligencia Artificial, haciendo énfasis en el uso de word embeddings y embeddings contextuales como herramientas fundamentales para el procesamiento del lenguaje natural. Estas técnicas permiten transformar palabras en vectores numéricos que capturan relaciones semánticas y sintácticas, facilitando que los modelos computacionales puedan interpretar y analizar el lenguaje humano de manera más eficiente.

A lo largo del desarrollo del taller, se implementaron diferentes actividades prácticas que incluyen la comparación entre representaciones tradicionales como One-Hot Encoding y representaciones densas, el entrenamiento de modelos como Word2Vec, así como la visualización de embeddings mediante técnicas de reducción de dimensionalidad como t-SNE. Además, se exploró la aplicación de estas representaciones en tareas reales como la clasificación de textos utilizando modelos de aprendizaje automático.

El objetivo principal de este trabajo fue comprender no solo el funcionamiento teórico de los embeddings, sino también su aplicación práctica en problemas reales, permitiendo evidenciar su importancia en el desarrollo de sistemas inteligentes basados en lenguaje.

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

2 Objetivos Generales

Comprender el uso de representaciones vectoriales de palabras (word embeddings) en el procesamiento del lenguaje natural, mediante la implementación de modelos como Word2Vec y la visualización de sus relaciones semánticas utilizando técnicas de reducción de dimensionalidad como t-SNE, con el fin de analizar cómo la inteligencia artificial interpreta el lenguaje humano.



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

3 Objetivos Específicos

- Implementar representaciones de palabras mediante modelos de embeddings como Word2Vec para transformar texto en vectores numéricos.
- Seleccionar palabras representativas del modelo entrenado y extraer sus vectores para su análisis.
- Aplicar la técnica de reducción de dimensionalidad t-SNE para visualizar los embeddings en un espacio bidimensional.
- Interpretar gráficamente las relaciones semánticas entre palabras según su cercanía en el espacio vectorial.
- Analizar la utilidad de los embeddings en tareas de procesamiento de lenguaje natural y clasificación de texto.

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





4 Marco Teórico

El procesamiento del lenguaje natural (PLN) es una rama de la inteligencia artificial que se enfoca en la interacción entre las computadoras y el lenguaje humano. Uno de los principales retos en este campo es la representación del texto de manera que los modelos computacionales puedan interpretarlo eficientemente.

Tradicionalmente, técnicas como el **One-Hot Encoding** han sido utilizadas para representar palabras como vectores binarios, donde cada palabra se identifica con una posición única en un vector de alta dimensión. Sin embargo, este enfoque presenta limitaciones importantes, como la alta dispersión de los datos y la incapacidad de capturar relaciones semánticas entre palabras.

Para superar estas limitaciones, surgen los **Word Embeddings**, que son representaciones vectoriales densas en espacios de menor dimensión. Estos embeddings permiten capturar similitudes semánticas y relaciones sintácticas entre palabras. Modelos como **Word2Vec**, basado en redes neuronales, aprenden estas representaciones a partir de grandes corpus de texto, logrando que palabras con significados similares tengan vectores cercanos en el espacio vectorial.

Además, existen técnicas de visualización como **t-SNE (t-Distributed Stochastic Neighbor Embedding)**, que permiten reducir la dimensionalidad de los embeddings para representarlos en espacios bidimensionales o tridimensionales, facilitando su interpretación.

En aplicaciones prácticas, los embeddings son ampliamente utilizados en tareas como clasificación de textos, análisis de sentimientos, traducción automática y sistemas de recomendación. Su capacidad para capturar el contexto y significado del lenguaje los convierte en una herramienta fundamental en el desarrollo de sistemas inteligentes modernos.

Finalmente, los avances recientes han dado lugar a los **embeddings contextuales**, utilizados en modelos más complejos como los basados en transformadores, los cuales consideran el contexto completo de una palabra dentro de una oración, mejorando significativamente el rendimiento en tareas de PLN.

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

5 Desarrollo

5.1 Instalación de Dependencias

```
# TODO: Instalar las siguientes librerías
# - gensim
# - nltk
# - scikit-learn
# - matplotlib
# - numpy
#
# INSTRUCCIONES:
# 1. Importa subprocess y sys
# 2. Crea una lista llamada 'librerías' con las librerías mencionadas
# 3. Usa un loop para instalar cada una con pip install
# 4. Imprime un mensaje de confirmación al final

import subprocess
import sys

# Lista de librerías
librerias = ['gensim', 'nltk', 'scikit-learn', 'matplotlib', 'numpy']

# Instalación automática
for lib in librerias:
    subprocess.check_call([sys.executable, "-m", "pip", "install", lib])

print("Todas las librerías fueron instaladas correctamente")

Todas las librerías fueron instaladas correctamente
```

Figura 1 Código del Ejercicio 1

5.2 Conceptos Fundamentales

```
# TODO: Comparar One-Hot Encoding vs Dense Embeddings
#
# INSTRUCCIONES:
# 1. Define un vocabulario: ['inteligencia', 'artificial', 'máquina', 'aprendizaje', 'datos']
# 2. Crea un vector One-Hot para la primera palabra (todos ceros excepto el índice 0)
# 3. Crea un embedding denso usando números aleatorios (np.random.randn)
# 4. Imprime ambos vectores con sus características
#
# PISTAS:
# - Usa np.zeros() para crear el vector one-hot
# - Usa np.random.seed(42) para reproducibilidad
# - Usa np.random.randn() para crear embeddings densos

import numpy as np
import numpy as np

# 1. Definir vocabulario
vocabulario = ['inteligencia', 'artificial', 'máquina', 'aprendizaje', 'datos']
tamano = len(vocabulario)

# 2. Crear vector One-Hot para la primera palabra (índice 0)
one_hot = np.zeros(tamano)
one_hot[0] = 1

# 3. Crear embedding denso con números aleatorios
np.random.seed(42) # Para reproducibilidad
embedding = np.random.randn(tamano)

# 4. Imprimir resultados
print("=====")
print("CONCEPTOS FUNDAMENTALES: ONE-HOT VS EMBEDDINGS")
print("=====\\n")

print("Vocabulario:", vocabulario)
print("Tamaño:", tamano)

print("\\nOne-Hot:", one_hot)
print("Propiedades: Muy disperso, no captura semántica")

print("\\nEmbedding:", embedding)
print("Propiedades: Denso, captura relaciones semánticas")
```

Figura 2 Código del Ejercicio 2



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

CONCEPTOS FUNDAMENTALES: ONE-HOT VS EMBEDDINGS

Vocabulario: ['inteligencia', 'artificial', 'máquina', 'aprendizaje', 'datos']
Tamaño: 5

One-Hot: [1. 0. 0. 0. 0.]

Propiedades: Muy disperso, no captura semántica

Embedding: [0.49671415 -0.1382643 0.64768854 1.52302986 -0.23415337]

Propiedades: Denso, captura relaciones semánticas

Figura 3 Resultado del Ejercicio 2

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación



5.3 Word2Vec - Entrenamiento Práctico

```
# TODO: Entrenar un modelo Word2Vec
#
# INSTRUCCIONES:
# 1. Importa Word2Vec de gensim
# 2. Importa funciones de nltk para tokenizar
# 3. Define un corpus de ejemplo sobre IA/ML (al menos 5 oraciones)
# 4. Tokeniza el corpus en oraciones y palabras
# 5. Entrena Word2Vec con los parámetros:
#     - vector_size=50
#     - window=5
#     - min_count=1
#     - sg=1 (Skip-gram)
# 6. Imprime información del modelo entrenado
#
# PISTAS:
# - Usa sent_tokenize para separar oraciones
# - Usa word_tokenize para separar palabras
# - Descarga los recursos necesarios de nltk con nltk.download()

from gensim.models import Word2Vec
from nltk.tokenize import sent_tokenize, word_tokenize
import nltk

# Descargas necesarias
nltk.download('punkt')
nltk.download('punkt_tab')

# Corpus
corpus = """
La inteligencia artificial está revolucionando el mundo.
El aprendizaje automático permite a las máquinas aprender.
Las redes neuronales procesan grandes cantidades de datos.
Los datos son fundamentales en la inteligencia artificial.
Los modelos de IA mejoran con más información.
"""

# Tokenización
oraciones = sent_tokenize(corpus)
tokens = [word_tokenize(oracion.lower()) for oracion in oraciones]

# Modelo
modelo = Word2Vec(
    sentences=tokens,
    vector_size=50,
    window=5,
    min_count=1,
    sg=1
)

print("Modelo entrenado correctamente")
```

Figura 4 Código del Ejercicio 3



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

```
[nltk_data] Downloading package punkt to /root/nltk_data...  
[nltk_data]   Unzipping tokenizers/punkt.zip.  
[nltk_data] Downloading package punkt_tab to /root/nltk_data...  
[nltk_data]   Unzipping tokenizers/punkt_tab.zip.  
Modelo entrenado correctamente
```

Figura 5 Resultado del Ejercicio 3



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

📍 Sede Quirinal: Calle 21 No. 6 - 01
📍 Sede Prado Alto: Calle 8 No. 32 - 49 PBX: (608) 8754220
📍 Sede Pitalito: Carrera 2 No. 1 - 27 - PBX: (608) 8350459
✉ Email: contacto@corhuila.edu.co - www.corhuila.edu.co
Personería Jurídica Res. Ministerio de Educación No. 21000 de Diciembre 22 de 1989
NIT. 800.107.584-2



CORPORACIÓN UNIVERSITARIA DEL HUILA - CORHUILA
"Diseño y prestación de servicios de docencia, investigación y extensión de programas de pregrado, aplicando todos los requisitos de las normas ISO implementadas en sus sedes Neiva y Pitalito"

5.4 Visualización con t-SNE

```
# TODO: Visualizar embeddings con t-SNE
#
# INSTRUCCIONES:
# 1. Selecciona 5 palabras que existan en el modelo entrenado
# 2. Obtén sus vectores del modelo
# 3. Usa t-SNE para reducir a 2 dimensiones (perplexity=2)
# 4. Crea un gráfico scatter con los puntos
# 5. Añade anotaciones con los nombres de las palabras
# 6. Añade título y etiquetas a los ejes
#
# PISTAS:
# - TSNE viene de sklearn.manifold
# - Usa plt.scatter() para graficar los puntos
# - Usa plt.annotate() para añadir etiquetas
# - Usa fit_transform() para ajustar y transformar los datos

from sklearn.manifold import TSNE
import matplotlib.pyplot as plt
import numpy as np

# Palabras válidas
palabras = ["inteligencia", "aprendizaje", "datos", "redes", "artificial"]

# Obtener vectores
vectores = [modelo.wv[p] for p in palabras]

# CONVERTIR A ARRAY
vectores = np.array(vectores)

# t-SNE
tsne = TSNE(n_components=2, perplexity=2, random_state=42)
reducido = tsne.fit_transform(vectores)

# Gráfico
plt.figure()

for i, palabra in enumerate(palabras):
    plt.scatter(reducido[i, 0], reducido[i, 1])
    plt.annotate(palabra, (reducido[i, 0], reducido[i, 1]))

plt.title("Embeddings Visualizados con t-SNE")
plt.xlabel("Dimensión 1")
plt.ylabel("Dimensión 2")

plt.show()
```

Figura 6 Código del Ejercicio 4



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

Embeddings Visualizados con t-SNE




Figura 7 Resultado del Ejercicio 4

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación



5.5 Clasificación de Textos con Embeddings

```
# TODO: Clasificar textos usando embeddings
#
# INSTRUCCIONES:
# 1. Define una función que calcule el embedding promedio de un texto
#   - Tokeniza el texto
#   - Obtén vectores de palabras que existan en el modelo
#   - Retorna el promedio de esos vectores
# 2. Crea un dataset con 4 textos de ejemplo y sus etiquetas (positivo=1, negativo=0)
# 3. Obtén los embeddings promedios para cada texto
# 4. Entrena un clasificador LogisticRegression
# 5. Evalúa la precisión en los datos de entrenamiento
# 6. Haz una predicción en un nuevo texto de prueba
#
# PISTAS:
# - np.mean() para promediar vectores
# - LogisticRegression de sklearn.linear_model
# - clf.fit() para entrenar
# - clf.score() para evaluar
# - clf.predict() para predecir

from sklearn.linear_model import LogisticRegression
import numpy as np
from nltk.tokenize import word_tokenize

# Función embedding promedio
def get_embedding_avg(texto, modelo):
    palabras = word_tokenize(texto.lower())
    vectores = [modelo.wv[p] for p in palabras if p in modelo.wv]

    if len(vectores) == 0:
        return np.zeros(modelo.vector_size)

    return np.mean(vectores, axis=0)
```

Figura 8 Código del Ejercicio 5

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación



```
# Dataset (4 textos)
textos = [
    "me encanta la inteligencia artificial",
    "los datos son muy importantes",
    "odio estudiar matemáticas",
    "aprendo cosas nuevas cada día"
]

etiquetas = [1, 1, 0, 1] # 1 positivo, 0 negativo

# Convertir a embeddings
X = np.array([get_embedding_avg(t, modelo) for t in textos])
y = np.array(etiquetas)

# Modelo
clf = LogisticRegression()
clf.fit(X, y)

# Evaluación
print("✓ Clasificador entrenado")
print("Precisión:", clf.score(X, y))

# Prueba
texto_prueba = "una película asombrosa"
embedding_test = get_embedding_avg(texto_prueba, modelo)

pred = clf.predict([embedding_test])

print("\nTexto:", texto_prueba)
print("Predicción:", "Positiva" if pred[0] == 1 else "Negativa")

✓ Clasificador entrenado
Precisión: 0.75

Texto: una película asombrosa
Predicción: Positiva
```

Figura 9 Continuación del Código mas Resultado del Ejercicio 5



CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

Conclusiones

El desarrollo del presente taller permitió aplicar de manera práctica los principales conceptos y técnicas del Procesamiento del Lenguaje Natural (NLP), evidenciando su utilidad en el análisis y tratamiento de datos textuales. A través de la ejecución de cada uno de los ejercicios, se logró implementar correctamente procesos como la limpieza y normalización de texto, la tokenización, la eliminación de stopwords y la reducción de palabras mediante stemming y lematización.

Asimismo, se adquirió experiencia en técnicas más avanzadas como el análisis de frecuencia de palabras, la extracción de entidades nombradas (NER) y el cálculo de similitud entre textos, lo que permitió comprender cómo se puede extraer información relevante y medir relaciones semánticas entre diferentes contenidos. La construcción de un pipeline completo de preprocesamiento facilitó la integración de todas estas etapas, demostrando la importancia de estructurar adecuadamente el flujo de procesamiento de datos.

Finalmente, el desarrollo del proyecto integrador de análisis de sentimientos permitió consolidar los conocimientos adquiridos, aplicándolos en un caso práctico que simula situaciones reales. En conjunto, este trabajo fortaleció tanto las habilidades técnicas en programación como la comprensión de cómo las máquinas pueden interpretar el lenguaje humano, resaltando el papel fundamental del NLP en el campo de la inteligencia artificial.

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación





CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

INSTITUCIÓN DE EDUCACIÓN SUPERIOR SUJETA A INSPECCIÓN
Y VIGILANCIA POR EL MINISTERIO DE EDUCACIÓN NACIONAL - SNIES 2828

Bibliografía

- [1] S. Russell y P. Norvig, Artificial Intelligence: A Modern Approach, Pearson Education, 1995.
- [2] C. M. Bishop, Pattern Recognition and Machine Learning, Springer-Verlag New York, 2006.
- [3] S. S. Haykin, Neural Networks and Learning Machines, Pearson Education / Prentice Hall., 2008.
- [4] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, O'Reilly Media, 2017.
- [5] I. Goodfellow, Y. Bengio y A. Courville, Deep Learning, MIT Press, 2016.

CORHUILA

CORPORACIÓN UNIVERSITARIA DEL HUILA
Vigilada Mineducación

